

Лабораторна робота № 1

Вхідний аналіз набору даних

Дисципліна: Інтелектуальний аналіз та візуалізація даних (СК26) **Тривалість:** 2 год аудиторно + 3 год самостійної роботи • **Максимальна оцінка:** 4 бали

Мета роботи

Пригадати роботу в Jupyter Notebook, бібліотеці `pandas` та побудову графіків — і зробити це не на навчальному прикладі, а на реальному файлі, який ніхто не готував спеціально для вас.

Ця робота виконується **до першої лекції**. Нічого нового знати не потрібно: усе, що знадобиться, ви вже проходили в попередніх курсах. Усі поняття, яких ви тут торкнетеся мимохідь, отримають назви й пояснення на лекціях 3 і 4.

Дані

Файл `20171129_FINAL_FINAL.xlsx`, аркуш `Sheet1` — спостереження космічної погоди за 28 серпня — 22 вересня 2017 року, зібрані з трьох різних джерел.

Файл видається **як є**, рівно в тому вигляді, у якому його колись вивантажили. Ніхто не приводив його до ладу, і саме в цьому сенс: справжні дані здебільшого надходять саме такими.

Що ви маєте зробити

Етап	Зміст	Де
1	Розібратися, що взагалі лежить у файлі	аудиторно
2	Виділити три таблиці й привести їх до робочого вигляду	аудиторно
3	Скласти паспорт даних: що є, чого бракує, що виглядає дивно	аудиторно
4	Об'єднати три таблиці в одну	аудиторно
5	Побудувати п'ять графіків, кожен — відповідь на питання	аудиторно + самостійно
6	Порівняти два графіки одних і тих самих даних	самостійно

Етап	Зміст	Де
7	Записати три спостереження про дані	самостійно
8	Декларація про використання інструментів ШІ	самостійно

Що здається

1. Цей файл `.ipynb` із заповненими розв'язками. **Ноутбук має виконуватися згори донизу на чистому ядрі** (Kernel → Restart & Run All) без помилок — це перевіряється першою дією на захисті.
2. Файл `master_hourly.csv` — об'єднана таблиця з етапу 4.
3. Експорт ноутбука у HTML або PDF.
4. Заповнена декларація (етап 8). Без неї фінальна самоперевірка не проходить.

Критерії оцінювання

Бали	Що досягнуто
0	Дані не опрацьовано, графіки не побудовано або побудовано з грубими помилками
1	Таблиці прочитано й кілька графіків побудовано, але типи графіків не відповідають даним, дивних значень не помічено
2	Таблиці розібрано й об'єднано, графіки коректні та підписані, але висновків під ними немає або вони формальні
4	Усе вище виконано, знайдено й пояснено дивні значення, під кожним графіком є змістовний висновок про дані

Головне про оцінку: бали ставляться не за наявність графіка, а за речення під ним. Код, який нічого не пояснює, коштує двох балів з чотирьох.

Нагадування про Jupyter

Якщо давно не працювали — три речі, які знадобляться сьогодні:

- `Shift+Enter` виконує клітинку, `Esc A` / `Esc B` додає клітинку вище / нижче, `Esc M` перетворює клітинку на текстову (Markdown), `Esc Y` — назад на код.
- **Порядок виконання має значення.** Якщо ви правили клітинки в довільному порядку, результат може залежати від історії запусків. Перед здачею обов'язково **Kernel → Restart & Run All** — так ви побачите ноутбук очима викладача.

- Текстові клітинки — не прикраса. Висновки пишуться в них, а не в коментарях до коду.
-

Крок 0. Ваші дані та варіант

Заповніть три змінні й виконайте обидві клітинки. Друга надрукує **ваше індивідуальне завдання** — воно відрізняється від завдання сусіда.

```
In [25]: ПІБ = 'Білоусов Михайло'          # напр. 'Шевченко Тарас'
ГРУПА = 'ШІ-32'          # напр. 'КН-31'
ВАРІАНТ = 1              # ваш номер за списком групи

assert ПІБ and ГРУПА and ВАРІАНТ, 'Заповніть ПІБ, ГРУПУ та ВАРІАНТ'
```

```
In [26]: # --- клітинку не редагувати: вона видає ваше персональне завдання -----
ПОТОКИ = ['P>1', 'P>5', 'P>10', 'P>30', 'P>50', 'P>100', 'E>0.8', 'E>2.0']

ПАРИ = [('швидкість вітру', 'густина вітру'),
        ('швидкість вітру', 'потік P>10'),
        ('густина вітру', 'потік P>1'),
        ('радіопотік F10.7', 'потік P>10'),
        ('радіопотік F10.7', 'швидкість вітру'),
        ('потік E>0.8', 'потік P>10')]

АГРЕГАТИ = ['середнє', 'максимум', 'медіана', 'мінімум']

ПИТАННЯ = [
    'Скільки годин за все вікно ваш потік перевищував своє власне медіанне з',
    'У яку добу середнє значення вашого потоку було найбільшим? А найменшим?',
    'О котрій годині доби потік E>0.8 у середньому найбільший? Побудуйте гра',
    'Яка частка рядків об'єднаної таблиці має пропуск хоча б в одному стовпц',
    'У який день радіопотік F10.7 був найбільшим і чи збігається цей день з',
    'Порівняйте медіану вашого потоку за перший і за другий тиждень спостере',
    'Скільки годин поспіль тривала найдовша неперервна серія «активних» годи',
    'Який зі стовпців об'єднаної таблиці має найбільший розкид відносно влас',
    'Яку частку сумарного значення вашого потоку за все вікно дали 24 години',
    'Скільки різних діб потрапило у групу «активні» і скільки – у групу «дуж',
]

i = int(ВАРІАНТ)
завдання = {
    'ваш потік': ПОТОКИ[(i * 3 + 1) % 8],
    'ваша пара для графіка 3': ' та '.join(ПАРИ[(i * 5 + 2) % 6]),
    'ваш агрегат для етапу 4': АГРЕГАТИ[(i * 5 + 1) % 4],
    'ваше додаткове питання': ПИТАННЯ[(i * 11 + 5) % 10],
}

print('ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · %s, %s, варіант %d' % (ПІБ, ГРУПА, i))
print('=' * 78)
for k, v in завдання.items():
    print('%-28s %s' % (k + ': ', v))
```

ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · Білоусов Михайло, ШІ-32, варіант 1

```
==
ваш потік: P>50
ваша пара для графіка 3: швидкість вітру та потік P>10
ваш агрегат для етапу 4: медіана
ваше додаткове питання: Скільки годин поспіль тривала найдовша неперервна серія «активних» годин (група з етапу 4)?
```

Далі за текстом **«ваш потік»** означає стовпець, названий у першому рядку завдання.

```
In [27]: !uv add pandas numpy matplotlib openpyxl
```

✗ No solution found when resolving dependencies for split (markers: python_full_version >= '3.14' and sys_platform == 'win32'):
└─▶ Because xelatex was not found in the package registry and your project depends on xelatex, we can conclude that your project's requirements are unsatisfiable.

hint: While the active Python version is 3.13, the resolution failed for other Python versions supported by your project. Consider limiting your project's supported Python versions using ``requires-python``.
help: If you want to add the package regardless of the failed resolution, provide the ``--frozen`` flag to skip locking and syncing.

```
In [28]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

pd.set_option('display.width', 200)
pd.set_option('display.max_columns', 40)
plt.rcParams.update({'figure.dpi': 110, 'axes.spines.top': False,
                    'axes.spines.right': False, 'font.size': 9})

ФАЙЛ = '20171129_FINAL_FINAL.xlsx'
```

Етап 1. Що взагалі лежить у файлі

Перше правило роботи з незнайомими даними: спершу подивитися, потім рахувати.

Завдання 1.1

Спробуйте прочитати аркуш `Sheet1` звичайним способом —

`pd.read_excel(ФАЙЛ)` — і виведіть перші рядки та типи стовпців.

Очікуваний результат: результат буде дивним. Подивіться на назви стовпців і на те, які там типи даних. Поясніть у наступній клітинці, чому так вийшло.

```
In [29]: # ВАШ КОД
pd.read_excel(ФАЙЛ)
```

Out[29]:

	Unnamed: 0	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	Unnamed: 2	Unnamed: 3	Uni
0	NaN	NaN	NaN	NaN	
1	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	
2	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	
3	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	
4	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	
...	...	...	...	...	...
7220	NaN	2017	9	21	
7221	NaN	2017	9	21	
7222	NaN	2017	9	21	
7223	NaN	2017	9	21	
7224	NaN	2017	9	21	

7225 rows × 32 columns

Відповідь 1.1: (чому звичайне читання дало саме такий результат)

Це пов'язано з тим, що читання просто виводить всю таблицю без перевірки на заголовки і т.д., просто сирі дані. Також воно приймає перший рядок за заголовок, що відключається через задання параметра `header`.

Завдання 1.2

Прочитайте аркуш ще раз, але **без заголовка**: `pd.read_excel(ФАЙЛ, header=None)`. Виведіть його розмір і подивіться на перші 30 рядків.

In [30]:

```
# ВАШ КОД
RAW = pd.read_excel(ФАЙЛ, header=None)

print(len(RAW))
RAW[:30]
```

7226

Out[30]:

	0	1	2	3	4	5	6
0	NaN	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	NaN	NaN	NaN	NaN	NaN
1	NaN		NaN	NaN	NaN	NaN	NaN
2	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN
3	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN
4	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN
5	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN
6	NaN	#	NaN	NaN	NaN	NaN	NaN
7	NaN	# Label: P > 1 = Particles at >1 Mev	NaN	NaN	NaN	NaN	NaN
8	NaN	# Label: P > 5 = Particles at >5 Mev	NaN	NaN	NaN	NaN	NaN
9	NaN	# Label: P >10 = Particles at >10 Mev	NaN	NaN	NaN	NaN	NaN
10	NaN	# Label: P >30 = Particles at >30 Mev	NaN	NaN	NaN	NaN	NaN
11	NaN	# Label: P >50 = Particles at >50 Mev	NaN	NaN	NaN	NaN	NaN
12	NaN	# Label: P>100 = Particles at >100 Mev	NaN	NaN	NaN	NaN	NaN
13	NaN	# Label: E>0.8 = Electrons at >0.8 Mev	NaN	NaN	NaN	NaN	NaN
14	NaN	# Label: E>2.0 = Electrons at >2.0 Mev	NaN	NaN	NaN	NaN	NaN
15	NaN	# Label: E>4.0 = Electrons at >4.0 Mev	NaN	NaN	NaN	NaN	NaN
16	NaN	# Units: Particles = Protons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN
17	NaN	# Units: Electrons = Electrons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN
18	NaN	# Source: GOES-15	NaN	NaN	NaN	NaN	NaN
19	NaN	# Location: W135	NaN	NaN	NaN	NaN	NaN
20	NaN	# Missing data: -1.00e+05	NaN	NaN	NaN	NaN	NaN
21	NaN		NaN	NaN	NaN	NaN	NaN
22	NaN	5-minute GOES-15 Solar Particle and Electron ...	NaN	NaN	NaN	NaN	NaN
23	NaN		NaN	NaN	NaN	Modified	Seconds
24	NaN		# UT	C D	ate	Time	Julian of the

	0	1	2	3	4	5	6
25	NaN	# YR	MO	DA	HHMM	Day	Day
26	NaN	2017	8	28	0	57993	0
27	NaN	2017	8	28	5	57993	300
28	NaN	2017	8	28	10	57993	600
29	NaN	2017	8	28	15	57993	900

Завдання 1.3

Для кожного стовпця порахуйте, скільки в ньому заповнених клітинок (`RAW.notna().sum()`), і виведіть результат.

Очікуваний результат: 32 числа. Серед них будуть нулі та згустки великих значень. За цими згустками видно, що в аркуші **не одна таблиця, а кілька**, вставлені поруч.

Питання: скільки таблиць в аркуші і які стовпці займає кожна?

```
In [31]: # ВАШ КОД
RAW.notna().sum()
```

```
Out[31]: 0      0
         1    7223
         2    7202
         3    7202
         4    7202
         5    7203
         6    7203
         7    7198
         8    7198
         9    7198
        10    7198
        11    7198
        12    7198
        13    7198
        14    7198
        15      0
        16     32
        17     26
        18     26
        19     26
        20      0
        21      0
        22      0
        23      0
        24    601
        25    601
        26    608
        27    602
        28    602
        29    602
        30    602
        31    602
dtype: int64
```

Відповідь 1.3: (скільки таблиць і які стовпці кожна займає)

З таблиці, перша стовпці (від нуля) 1-14, друга 16-19, третя 24-31

Завдання 1.4

Над кожною таблицею є кілька текстових рядків — це службовий опис від тих, хто дані збирав. Виведіть їх і випишіть для кожної таблиці **джерело даних та одиниці вимірювання**.

Це найкорисніші п'ять хвилин роботи: жодної з цих відомостей у самій таблиці немає, і без них ви не знатимете, у чому вимірюєте.

```
In [32]: # A
RAW.iloc[:30, 1:14]
```

Out[32]:

	1	2	3	4	5	6	7
0	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN	NaN
3	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN	NaN
4	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN	NaN
5	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN	NaN
6	#	NaN	NaN	NaN	NaN	NaN	NaN
7	# Label: P > 1 = Particles at >1 Mev	NaN	NaN	NaN	NaN	NaN	NaN
8	# Label: P > 5 = Particles at >5 Mev	NaN	NaN	NaN	NaN	NaN	NaN
9	# Label: P >10 = Particles at >10 Mev	NaN	NaN	NaN	NaN	NaN	NaN
10	# Label: P >30 = Particles at >30 Mev	NaN	NaN	NaN	NaN	NaN	NaN
11	# Label: P >50 = Particles at >50 Mev	NaN	NaN	NaN	NaN	NaN	NaN
12	# Label: P>100 = Particles at >100 Mev	NaN	NaN	NaN	NaN	NaN	NaN
13	# Label: E>0.8 = Electrons at >0.8 Mev	NaN	NaN	NaN	NaN	NaN	NaN
14	# Label: E>2.0 = Electrons at >2.0 Mev	NaN	NaN	NaN	NaN	NaN	NaN
15	# Label: E>4.0 = Electrons at >4.0 Mev	NaN	NaN	NaN	NaN	NaN	NaN
16	# Units: Particles = Protons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN	NaN
17	# Units: Electrons = Electrons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN	NaN
18	# Source: GOES-15	NaN	NaN	NaN	NaN	NaN	NaN
19	# Location: W135	NaN	NaN	NaN	NaN	NaN	NaN
20	# Missing data: -1.00e+05	NaN	NaN	NaN	NaN	NaN	NaN
21	NaN	NaN	NaN	NaN	NaN	NaN	NaN
22	5-minute GOES-15 Solar Particle and Electron ...	NaN	NaN	NaN	NaN	NaN	NaN
23	NaN	NaN	NaN	NaN	Modified	Seconds	NaN
24	# UT	C D	ate	Time	Julian	of the	NaN
25	# YR	MO	DA	HHMM	Day	Day	P > 1
26	2017	8	28	0	57993	0	12

	1	2	3	4	5	6	7
27	2017	8	28	5	57993	300	19.4
28	2017	8	28	10	57993	600	8.48
29	2017	8	28	15	57993	900	15.4

```
In [33]: # B  
RAW.iloc[:30, 16:20]
```

Out[33]:

	16	17	18	19
0	NaN	NaN	NaN	NaN
1	NaN	NaN	NaN	NaN
2	NaN	NaN	NaN	NaN
3	NaN	NaN	NaN	NaN
4	NaN	NaN	NaN	NaN
5	NaN	NaN	NaN	NaN
6	NaN	NaN	NaN	NaN
7	NaN	NaN	NaN	NaN
8	NaN	NaN	NaN	NaN
9	NaN	NaN	NaN	NaN
10	NaN	NaN	NaN	NaN
11	NaN	NaN	NaN	NaN
12	NaN	NaN	NaN	NaN
13	ftp://ftp.swpc.noaa.gov/pub/indices/old_indice...	NaN	NaN	NaN
14	NaN	NaN	NaN	NaN
15	Product: Daily Solar Data quar_DSD.txt	NaN	NaN	NaN
16	:Issued: 0825 UT 04 Oct 2017	NaN	NaN	NaN
17	#	NaN	NaN	NaN
18	# Prepared by the U.S. Dept. of Commerce, NOA...	NaN	NaN	NaN
19	# Please send comments and suggestions to SWP...	NaN	NaN	NaN
20	NaN	NaN	NaN	NaN
21	NaN	NaN	NaN	NaN
22	NaN	NaN	NaN	NaN
23	Quarterly Daily Solar Data	NaN	NaN	NaN
24	NaN	NaN	NaN	NaN
25	NaN	NaN	NaN	NaN
26	NaN	Month	Date	Radio Flux 10.7
27	2017	8	28	82
28	2017	8	29	84

	16	17	18	19
29	2017	8	30	87

```
In [34]: # C  
RAW.iloc[:30, 24:32]
```

Out[34]:

	24	25		26	27	28	29	30	31
0	NaN	NaN	http://umtof.umd.edu/pm/crn/	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
2	NaN	NaN	SOHO CELIAS Proton Monitor	NaN	NaN	NaN	NaN	NaN	NaN
3	NaN	NaN	Solar Wind Parameters for Carrington Rotation ...	NaN	NaN	NaN	NaN	NaN	NaN
4	NaN	NaN	Proton speed [km/sec]	NaN	NaN	NaN	NaN	NaN	NaN
5	NaN	NaN	Proton density [protons per cubic centimeter]	NaN	NaN	NaN	NaN	NaN	NaN
6	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
7	NaN	NaN	Measurement time (Year, Month, Day of Month, D...	NaN	NaN	NaN	NaN	NaN	NaN
8	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
9	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
10	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
11	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
12	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
13	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
14	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
15	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
16	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
17	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
18	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
19	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
20	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
21	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
22	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
23	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
24	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
25	NaN	NaN		NaN	NaN	NaN	NaN	NaN	NaN
26	NaN	NaN		# YR	MO	DA	HH	SPEED	DENSITY
27	0.0	0.0		17	8	28	0	285	3

	24	25		26	27	28	29	30	31
28	1.0	1.0		17	8	28	1	305	3.4
29	2.0	2.0		17	8	28	2	309	1.7

Відповідь 1.4:

Таблиця	Джерело	Одиниці вимірювань
A	ftp://ftp.swpc.noaa.gov/pub/lists/particle/20170901_Gs_part_5m.txt	Protons/cm ² * Electrons/cm ² ·s
B	ftp://ftp.swpc.noaa.gov/pub/indices/old_indices/2017Q3_DSD.txt	Radio flux 10.7 (sfu)
C	http://umtof.umd.edu/pm/crn/	Proton speed [km/sec], Proto density [protons/cm ³]

Етап 2. Три таблиці в робочому вигляді

У файлі три таблиці. Ось що в них лежить — решту ви вже знайшли самі:

Таблиця	Стовпці аркуша	Що це	Один рядок =
A	B–O	вимірювання із супутника GOES-15: потоки частинок різної енергії	5 хвилин
B	Q–T	добовий показник сонячної активності F10.7	доба
C	Y–AF	швидкість і густина сонячного вітру	година

Завдання 2.1

Виділіть кожну таблицю в окремий `DataFrame` — назвіть їх `A`, `B` і `C`. Дайте стовпцям осмислені назви й перетворіть значення на числа (`pd.to_numeric(..., errors='coerce')` стане в пригоді).

```
In [35]: # ВАШ КОД
A = RAW.iloc[26:, 1:15]
B = RAW.iloc[27:, 16:20]
C = RAW.iloc[27:, 26:32]
A = A.loc[:, A.last_valid_index()].convert_dtypes()
B = B.loc[:, B.last_valid_index()].convert_dtypes()
```

```

C = C.loc[:C.last_valid_index()].convert_dtypes()

A.columns = RAW.iloc[23:26, 1:15].fillna("").astype(str).agg(' '.join, axis=
A.columns = ["year", "month", "day", "HHMM"] + [i.lstrip() for i in list(A.c
B.columns = ["year"] + list(RAW.iloc[26, 17:20])
C.columns = ["year", "month", "day", "hour"] + list(RAW.iloc[26, 30:32])

```

Завдання 2.2

У кожній таблиці дата й час записані **по-різному** й розкидані по кількох стовпцях. Зберіть для кожної таблиці один стовпець `ts` типу `datetime`.

Після цього обов'язково виведіть для кожної таблиці найранішу й найпізнішу дату.

Очікуваний результат: усі три таблиці мають лежати в межах серпня-вересня 2017 року. Якщо у вас вийшов інший рік — придивіться, як записано рік у тій таблиці, і виправте.

```

In [36]: # ВАШ КОД
A["hour"] = A['HHMM'] // 100
A["minute"] = A['HHMM'] % 100
A["ts"] = pd.to_datetime(A[['year', 'month', 'day', 'hour', 'minute']])

B["ts"] = pd.to_datetime(B[['year', 'Month', 'Date']].rename(
    columns={
        'Month': 'month',
        'Date': 'day'
    }))

C.loc[C["year"] < 100, "year"] += 2000
C["ts"] = pd.to_datetime(C[['year', 'month', 'day', 'hour']])

for n, i in (('A', A), ('B', B), ('C', C)):
    print(f'Table {n}: min {min(i["ts"])}, max {max(i["ts"])}')

```

Table A: min 2017-08-28 00:00:00, max 2017-09-21 23:55:00

Table B: min 2017-08-28 00:00:00, max 2017-09-21 00:00:00

Table C: min 2017-08-28 00:00:00, max 2017-09-22 00:00:00

Самоперевірка етапу 2. Клітинка має виконатися без помилок.

```

In [37]: assert len(A) == 7200, 'у таблиці A має бути 7200 рядків, а є %d' % len(A)
assert len(B) == 25, 'у таблиці B має бути 25 рядків, а є %d' % len(B)
assert len(C) == 601, 'у таблиці C має бути 601 рядок, а є %d' % len(C)
for назва, т in (('A', A), ('B', B), ('C', C)):
    рік = pd.to_datetime(т['ts']).dt.year
    assert рік.min() == 2017 and рік.max() == 2017, 'у таблиці %s рік не 2017'
print('Етап 2 пройдено')

```

Етап 2 пройдено

Етап 3. Паспорт даних

Завдання 3.1

Для кожної таблиці виведіть: розмір, типи стовпців, кількість пропусків у кожному стовпці, кількість повних дублікатів рядків і описові статистики (`describe()`).

```
In [38]: # ВАШ КОД
for n, i in (('A', A), ('B', B), ('C', C)):
    print(f'=== {n} ===')
    print(f'Length = {len(i)}')
    print('Dtypes:')
    print(i.dtypes)
    print('Count of NAs per col:')
    print(i.isna().sum())
    print(f'Count of full duplicates: {i.duplicated().sum()}')
    print('Describe:')
    print(i.describe())
```

=== A ===

Length = 7200

Dtypes:

year	Int64
month	Int64
day	Int64
HHMM	Int64
Modified Julian Day	Int64
Seconds of the Day	Int64
P > 1	Float64
P > 5	Float64
P >10	Float64
P >30	Float64
P >50	Float64
P>100	Float64
E>0.8	Float64
E>2.0	Float64
hour	Int64
minute	Int64
ts	datetime64[us]

dtype: object

Count of NAs per col:

year	0
month	0
day	0
HHMM	0
Modified Julian Day	0
Seconds of the Day	0
P > 1	3
P > 5	3
P >10	3
P >30	3
P >50	3
P>100	3
E>0.8	3
E>2.0	3
hour	0
minute	0
ts	0

dtype: int64

Count of full duplicates: 0

Describe:

	year	month	day	HHMM	Modified Julian Day	Seconds of the Day	P > 1	P > 5	P >10	P >30	P >50	P>100
count	7200.0	7200.0	7200.0	7200.0	7200.0	7200.0	7200.0	7197.0	7197.0	7197.0	7197.0	7197.0
mean	2017.0	8.84	13.96	1177.5	58005.0	43050.0	689.325064	156.626057	76.47402	18.838604	7.44684	1.65929
min	2017.0	8.0	1.0	0.0	57993.0	0.0	0.429	0.151	0.117	0.0576	0.0455	0.0224
25%	2017.0	9.0	7.0	588.75	57999.0	21525.0	11.7	0.279	0.186	0.0984	0.0597	0.0263

22200.0	552.0	5.75				
50%	2017.0	9.0	13.0	1177.5		58005.0
43050.0	55.4	0.632	0.376	0.146	0.0866	0.0363
68600.0	4290.0	11.5				
75%	2017.0	9.0	19.0	1766.25		58011.0
64575.0	560.0	107.0	35.8	0.99	0.249	0.067
143000.0	14100.0	17.25				
max	2017.0	9.0	31.0	2355.0		58017.0
86100.0	32500.0	2890.0	1330.0	399.0	191.0	61.5
259000.0	110000.0	23.0				
std	0.0	0.366632	8.775483	692.481902		7.211603
943.113498	1625.968447	390.921861	222.362627	67.265595	28.620524	7.158
89	65728.005824	16920.617446	6.922667			

	minute	ts
count	7200.0	7200
mean	27.5	2017-09-09 11:57:30
min	0.0	2017-08-28 00:00:00
25%	13.75	2017-09-03 05:58:45
50%	27.5	2017-09-09 11:57:30
75%	41.25	2017-09-15 17:56:15
max	55.0	2017-09-21 23:55:00
std	17.261461	NaN

=== B ===

Length = 25

Dtypes:

year	Int64
Month	Int64
Date	Int64
Radio Flux 10.7	Int64
ts	datetime64[us]

dtype: object

Count of NAs per col:

year	0
Month	0
Date	0
Radio Flux 10.7	0
ts	0

dtype: int64

Count of full duplicates: 0

Describe:

	year	Month	Date	Radio Flux 10.7	ts
count	25.0	25.0	25.0	25.0	25
mean	2017.0	8.84	13.96	92.68	2017-09-09 00:00:00
min	2017.0	8.0	1.0	71.0	2017-08-28 00:00:00
25%	2017.0	9.0	7.0	74.0	2017-09-03 00:00:00
50%	2017.0	9.0	13.0	84.0	2017-09-09 00:00:00
75%	2017.0	9.0	19.0	107.0	2017-09-15 00:00:00
max	2017.0	9.0	31.0	140.0	2017-09-21 00:00:00
std	0.0	0.374166	8.955817	22.206831	NaN

=== C ===

Length = 601

Dtypes:

year	Int64
month	Int64
day	Int64

```

hour          Int64
SPEED         Int64
DENSITY       Float64
ts            datetime64[us]
dtype: object
Count of NAs per col:
year          0
month         0
day           0
hour          0
SPEED         0
DENSITY       0
ts            0
dtype: int64
Count of full duplicates: 0
Describe:

```

	year	month	day	hour	SPEED	DENSITY	
ts							
count	601.0	601.0	601.0	601.0	601.0	601.0	601
mean	2017.0	8.840266	13.973378	11.480865	506.547421	2.907654	2017-09-09 12:00:00
min	2017.0	8.0	1.0	0.0	-1.0	-1.0	2017-08-28 00:00:00
25%	2017.0	9.0	7.0	5.0	447.0	1.8	2017-09-03 06:00:00
50%	2017.0	9.0	13.0	11.0	517.0	2.4	2017-09-09 12:00:00
75%	2017.0	9.0	19.0	17.0	584.0	3.4	2017-09-15 18:00:00
max	2017.0	9.0	31.0	23.0	806.0	31.7	2017-09-22 00:00:00
std	0.0	0.366664	8.781	6.938063	125.073291	2.637873	
NaN							

Завдання 3.2 — дивні значення

Подивіться на рядок `min` у таблиці `describe()` для таблиці `C`.

Швидкість і густина — фізичні величини, які **не можуть бути від'ємними**.

Знайдіть від'ємні значення, порахуйте, скільки їх, і поверніться до службового опису з завдання 1.4: там написано, що вони означають.

Замініть ці значення на `NaN` і покажіть, як після цього змінилися середнє й мінімум.

Очікуваний результат: два числа «до» і «після» для кожного зі стовпців.

```

In [39]: # ВАШ КОД
print('=== BEFORE ===')
print('Describe:')
print(C.describe())
print('Speed negative:')

```

```
print(C.loc[C['SPEED'] < 0])
print(f'Count: {len(C.loc[C['SPEED'] < 0])}')
print('Density negative:')
print(C.loc[C['DENSITY'] < 0])
print(f'Count: {len(C.loc[C['DENSITY'] < 0])}')

C['SPEED'] = C['SPEED'].mask(C['SPEED'] < 0)
C['DENSITY'] = C['DENSITY'].mask(C['DENSITY'] < 0)

print('=== AFTER ===')
print('Describe:')
print(C.describe())
print('Speed negative:')
print(C.loc[C['SPEED'] < 0])
print(f'Count: {len(C.loc[C['SPEED'] < 0])}')
print('Density negative:')
print(C.loc[C['DENSITY'] < 0])
print(f'Count: {len(C.loc[C['DENSITY'] < 0])}')
```

=== BEFORE ===

Describe:

	year	month	day	hour	SPEED	DENSITY	
ts							
count	601.0	601.0	601.0	601.0	601.0	601.0	
601							
mean	2017.0	8.840266	13.973378	11.480865	506.547421	2.907654	2017-09
-09 12:00:00							
min	2017.0	8.0	1.0	0.0	-1.0	-1.0	2017-08
-28 00:00:00							
25%	2017.0	9.0	7.0	5.0	447.0	1.8	2017-09
-03 06:00:00							
50%	2017.0	9.0	13.0	11.0	517.0	2.4	2017-09
-09 12:00:00							
75%	2017.0	9.0	19.0	17.0	584.0	3.4	2017-09
-15 18:00:00							
max	2017.0	9.0	31.0	23.0	806.0	31.7	2017-09
-22 00:00:00							
std	0.0	0.366664	8.781	6.938063	125.073291	2.637873	
NaN							

Speed negative:

	year	month	day	hour	SPEED	DENSITY	ts
202	2017	9	4	7	-1	-1.0	2017-09-04 07:00:00
203	2017	9	4	8	-1	-1.0	2017-09-04 08:00:00
204	2017	9	4	9	-1	-1.0	2017-09-04 09:00:00
205	2017	9	4	10	-1	-1.0	2017-09-04 10:00:00
206	2017	9	4	11	-1	-1.0	2017-09-04 11:00:00
207	2017	9	4	12	-1	-1.0	2017-09-04 12:00:00
208	2017	9	4	13	-1	-1.0	2017-09-04 13:00:00
209	2017	9	4	14	-1	-1.0	2017-09-04 14:00:00

Count: 8

Density negative:

	year	month	day	hour	SPEED	DENSITY	ts
202	2017	9	4	7	-1	-1.0	2017-09-04 07:00:00
203	2017	9	4	8	-1	-1.0	2017-09-04 08:00:00
204	2017	9	4	9	-1	-1.0	2017-09-04 09:00:00
205	2017	9	4	10	-1	-1.0	2017-09-04 10:00:00
206	2017	9	4	11	-1	-1.0	2017-09-04 11:00:00
207	2017	9	4	12	-1	-1.0	2017-09-04 12:00:00
208	2017	9	4	13	-1	-1.0	2017-09-04 13:00:00
209	2017	9	4	14	-1	-1.0	2017-09-04 14:00:00

Count: 8

=== AFTER ===

Describe:

	year	month	day	hour	SPEED	DENSITY	
ts							
count	601.0	601.0	601.0	601.0	593.0	593.0	
601							
mean	2017.0	8.840266	13.973378	11.480865	513.394604	2.960371	2017-09
-09 12:00:00							
min	2017.0	8.0	1.0	0.0	277.0	0.1	2017-08
-28 00:00:00							
25%	2017.0	9.0	7.0	5.0	449.0	1.8	2017-09
-03 06:00:00							
50%	2017.0	9.0	13.0	11.0	520.0	2.5	2017-09
-09 12:00:00							

```

75%      2017.0      9.0      19.0      17.0      585.0      3.4  2017-09
-15 18:00:00
max      2017.0      9.0      31.0      23.0      806.0      31.7  2017-09
-22 00:00:00
std      0.0  0.366664      8.781  6.938063  111.025317  2.615965
NaN
Speed negative:
Empty DataFrame
Columns: [year, month, day, hour, SPEED, DENSITY, ts]
Index: []
Count: 0
Density negative:
Empty DataFrame
Columns: [year, month, day, hour, SPEED, DENSITY, ts]
Index: []
Count: 0

```

Відповідь 3.2: (що це за значення, скільки їх, як вони спотворювали середнє)

Таких значень 8, вони згруповані між собою в часі (4 вересня від 7 до 14 год) і мають обидва значення -1, що може свідчити про те, що вимірювальне обладнання в той час не працювало

Завдання 3.3 — питання на подумати

У таблиці A є стовпці, для яких `describe()` слухняно рахує середнє й стандартне відхилення, хоча ці числа не мають жодного сенсу.

Знайдіть їх і поясніть своїми словами, чому середнє для них безглузде.

Підказка: не кожне число в таблиці є результатом вимірювання.

Це питання не має однієї «правильної» відповіді з підручника — на нього ви відповідаєте з власного здорового глузду. Формальне пояснення буде на лекції 3.

```
In [40]: # ВАШ КОД
A.describe()
```

Out[40]:

	year	month	day	HHMM	Modified Julian Day	Seconds of the Day	P > 1
count	7200.0	7200.0	7200.0	7200.0	7200.0	7200.0	7197.0
mean	2017.0	8.84	13.96	1177.5	58005.0	43050.0	689.325064 1
min	2017.0	8.0	1.0	0.0	57993.0	0.0	0.429
25%	2017.0	9.0	7.0	588.75	57999.0	21525.0	11.7
50%	2017.0	9.0	13.0	1177.5	58005.0	43050.0	55.4
75%	2017.0	9.0	19.0	1766.25	58011.0	64575.0	560.0
max	2017.0	9.0	31.0	2355.0	58017.0	86100.0	32500.0
std	0.0	0.366632	8.775483	692.481902	7.211603	24943.113498	1625.968447 3

Відповідь 3.3: (які це стовпці та чому середнє для них не має сенсу)

Часові значення (рік, місяць і т.д.), бо вони не описують змінну величину, а лише визначають час вимірювання

Етап 4. Об'єднання трьох таблиць в одну

Таблиці мають різний крок у часі: 5 хвилин, година і доба. Щоб працювати з ними разом, потрібна спільна сітка. Беремо **годину**.

Кожна таблиця потребує своєї дії:

1. **A: 5 хвилин** → **година**. Кілька рядків згортаються в один — це `resample` + агрегація.
2. **C: уже година**. Просте з'єднання по спільному стовпцю `ts` — `merge`.

3. **В: доба** → **година**. Навпаки, одне значення розтягується на 24 години доби.

Завдання 4.1

Зведіть таблицю A до погодинної сітки. Для кожного потоку порахуйте **два** числа за годину: середнє і максимум.

```
In [41]: # ВАШ КОД
A = A.set_index("ts")
A_h = A.resample("1h").agg(["mean", "max"])
A = A.reset_index()
A_h
```

Out[41]:

	year		month		day		HHMM		Modified Julian Day		Secon
	mean	max	mean	max	mean	max	mean	max	mean	max	mea
ts											
2017-08-28 00:00:00	2017.0	2017	8.0	8	28.0	28	27.5	55	57993.0	57993	1650.
2017-08-28 01:00:00	2017.0	2017	8.0	8	28.0	28	127.5	155	57993.0	57993	5250.
2017-08-28 02:00:00	2017.0	2017	8.0	8	28.0	28	227.5	255	57993.0	57993	8850.
2017-08-28 03:00:00	2017.0	2017	8.0	8	28.0	28	327.5	355	57993.0	57993	12450.
2017-08-28 04:00:00	2017.0	2017	8.0	8	28.0	28	427.5	455	57993.0	57993	16050.
...	...	...	...	...	...	...	...	...	...	...	.
2017-09-21 19:00:00	2017.0	2017	9.0	9	21.0	21	1927.5	1955	58017.0	58017	70050.
2017-09-21 20:00:00	2017.0	2017	9.0	9	21.0	21	2027.5	2055	58017.0	58017	73650.
2017-09-21 21:00:00	2017.0	2017	9.0	9	21.0	21	2127.5	2155	58017.0	58017	77250.
2017-09-21 22:00:00	2017.0	2017	9.0	9	21.0	21	2227.5	2255	58017.0	58017	80850.
2017-09-21 23:00:00	2017.0	2017	9.0	9	21.0	21	2327.5	2355	58017.0	58017	84450.

600 rows × 32 columns

Завдання 4.2

У вашому завданні названо агрегат (середнє , максимум , медіана або мінімум).

Візьміть ваш потік за одну добу, порахуйте для нього по годинах ваш агрегат і ще один на ваш вибір, і побудуйте обидві криві на одному графіку.

Питання: чим вони відрізняються і в якій ситуації різниця між ними стане суттєвою?


```
In [42]: # ВАШ КОД
A = A.set_index("ts")
A_h_my = A["P >50"].iloc[:24*12].resample("1h").agg(["median", "mean"])
A = A.reset_index()
A_h_my
```

Out[42]:

	median	mean
ts		
2017-08-28 00:00:00	0.0613	0.077583
2017-08-28 01:00:00	0.05315	0.0587
2017-08-28 02:00:00	0.06275	0.069642
2017-08-28 03:00:00	0.05795	0.068092
2017-08-28 04:00:00	0.06155	0.07285
2017-08-28 05:00:00	0.05565	0.063692
2017-08-28 06:00:00	0.067	0.066992
2017-08-28 07:00:00	0.0635	0.076817
2017-08-28 08:00:00	0.0727	0.074467
2017-08-28 09:00:00	0.0757	0.076192
2017-08-28 10:00:00	0.061	0.067433
2017-08-28 11:00:00	0.05575	0.063942
2017-08-28 12:00:00	0.06965	0.070075
2017-08-28 13:00:00	0.0543	0.062367
2017-08-28 14:00:00	0.0798	0.090042
2017-08-28 15:00:00	0.05785	0.067958
2017-08-28 16:00:00	0.07425	0.0772
2017-08-28 17:00:00	0.076	0.082908
2017-08-28 18:00:00	0.057	0.072483
2017-08-28 19:00:00	0.065	0.071167
2017-08-28 20:00:00	0.05155	0.053517
2017-08-28 21:00:00	0.0789	0.081417
2017-08-28 22:00:00	0.06375	0.0709
2017-08-28 23:00:00	0.08165	0.0835

```
In [43]: A_h_my.plot(figsize=[8,6], linewidth=2)

plt.title("P>50 median vs mean aggregation")
plt.xlabel('Time')
plt.ylabel('Count of P>50')
plt.grid(True)
plt.show()
```



Відповідь 4.2: (чим відрізняються криві та коли це важливо)

Криві відрізняються досить суттєво (середнє значення скрізь більше). Це може свідчити про те, що були наявні спалахи кількості частинок у деякі 5-хвилинні періоди, або про те, що розподіл не є нормальним у будь-якому іншому сенсі цього слова.

Завдання 4.3

Об'єднайте три таблиці в одну — назвіть її `M`. Виведіть її розмір і всі рядки, у яких є хоча б один пропуск.

Зверніть увагу: таблиці закінчуються не в один і той самий момент. Тому результат залежить від того, який тип об'єднання ви оберете (`how='inner'` чи

how='outer'). Спробуйте обидва, подивіться, чим відрізняється кількість рядків, і поясніть свій вибір.

```
In [44]: # ВАШ КОД
B = B.set_index("ts")
B_h = B.resample("1h").ffill()
B = B.reset_index()

C_h = C.set_index("ts")
M = pd.concat([A_h, B_h, C_h], axis=1, join="outer").fillna(0)
M = M[['SPEED', 'DENSITY', 'Radio Flux 10.7'] + [i for i in M.columns if i[0] in 'A-C']]
M
```

Out[44]:

	SPEED	DENSITY	Radio Flux 10.7	(P > 1, mean)	(P > 1, max)	(P > 5, mean)	(P > 5, max)	(P >10, mean)	(P >10, max)	
ts										
2017-08-28 00:00:00	285	3.0	82	9.778333	19.4	0.324917	0.69	0.192917	0.314	
2017-08-28 01:00:00	305	3.4	82	7.994167	13.6	0.291667	0.512	0.156583	0.259	C
2017-08-28 02:00:00	309	1.7	82	6.099167	10.8	0.283	0.479	0.177667	0.321	
2017-08-28 03:00:00	304	2.0	82	4.7525	7.76	0.236833	0.329	0.166333	0.244	C
2017-08-28 04:00:00	302	2.3	82	4.158333	6.62	0.334917	0.539	0.208333	0.309	
...	...	...	...	...	...	...	...	...	...	
2017-09-21 20:00:00	379	1.8	0	42.1025	78.9	0.3975	0.833	0.226833	0.429	C
2017-09-21 21:00:00	380	1.8	0	50.783333	71.7	0.48925	0.788	0.317583	0.501	C
2017-09-21 22:00:00	387	1.1	0	39.0	48.8	0.35	0.536	0.20025	0.31	C
2017-09-21 23:00:00	380	1.0	0	28.825	42.1	0.465	0.861	0.257833	0.506	C
2017-09-22 00:00:00	381	1.0	0	0.0	0.0	0.0	0.0	0.0	0.0	

601 rows × 19 columns

Відповідь 4.3: (який тип об'єднання обрано, скільки рядків дає кожен і чому)

inner дає тільки рядки, де наявний найкоротший dataframe, outer - навпаки, замінюючи інші на NA. Я обрав outer, бо різниця між ними не є великою (601

проти 577)

Завдання 4.4 — поділ на групи

Щоб далі було що з чим порівнювати, поділіть години на три групи за значенням **максимуму потоку P>10 за годину**:

Група	Умова
тиха	менше 10
активна	від 10 до 1000
дуже активна	1000 і більше

Додайте до `M` стовпець `група` і виведіть, скільки годин потрапило в кожную.

Це не вигадані числа: саме такі пороги використовує метеослужба космічної погоди NOAA. Чому вони саме такі — питання не сьогоднішньої роботи.

```
In [45]: # ВАШ КОД
conds = [
    (M[('P >10', 'max')] < 10),
    (M[('P >10', 'max')] >= 10) & (M[('P >10', 'max')] <= 1000),
    (M[('P >10', 'max')] > 1000)
]
choices = ['тиха', 'активна', 'дуже активна']
M['група'] = np.select(conds, choices, default='тиха')
```

```
In [46]: M = M.reset_index()
M
```

Out[46]:

	ts	SPEED	DENSITY	Radio Flux 10.7	(P > 1, mean)	(P > 1, max)	(P > 5, mean)	(P > 5, max)	(P >10, mean)	> mi
0	2017-08-28 00:00:00	285	3.0	82	9.778333	19.4	0.324917	0.69	0.192917	0.3
1	2017-08-28 01:00:00	305	3.4	82	7.994167	13.6	0.291667	0.512	0.156583	0.2
2	2017-08-28 02:00:00	309	1.7	82	6.099167	10.8	0.283	0.479	0.177667	0.3
3	2017-08-28 03:00:00	304	2.0	82	4.7525	7.76	0.236833	0.329	0.166333	0.2
4	2017-08-28 04:00:00	302	2.3	82	4.158333	6.62	0.334917	0.539	0.208333	0.3
...	...	...	...	...	...	...	...	...	...	...
596	2017-09-21 20:00:00	379	1.8	0	42.1025	78.9	0.3975	0.833	0.226833	0.4
597	2017-09-21 21:00:00	380	1.8	0	50.783333	71.7	0.48925	0.788	0.317583	0.5
598	2017-09-21 22:00:00	387	1.1	0	39.0	48.8	0.35	0.536	0.20025	0.
599	2017-09-21 23:00:00	380	1.0	0	28.825	42.1	0.465	0.861	0.257833	0.5
600	2017-09-22 00:00:00	381	1.0	0	0.0	0.0	0.0	0.0	0.0	0.

601 rows × 11 columns

Самоперевірка етапу 4.

```
In [47]: assert M is not None, 'таблиця M не побудована'
assert 'ts' in M.columns, 'у таблиці M потрібен стовпець ts'
assert 'група' in M.columns, 'у таблиці M потрібен стовпець «група»'
```

```
assert 590 <= len(M) <= 605, 'очікується близько 600 рядків, а є %d — переві  
print('Етап 4 пройдено:', len(M), 'рядків')
```

Етап 4 пройдено: 601 рядків

Етап 5. П'ять графіків — п'ять питань

Графік будується як **відповідь на питання**, а не «щоб був».

Вимоги до кожного графіка:

- підписані обидві осі, з одиницями вимірювання;
- заголовок;
- під графіком, у текстовій клітинці, — **одне речення про дані**. Не «на графіку зображено потік протонів», а твердження на кшталт «більшість годин потік не перевищує 60, але кілька годин дають значення у сотні разів більші».

Не кожне питання має відповідь «так, зв'язок є». Якщо на графіку нічого не видно — так і напишіть. Відсутність зв'язку — це теж результат, і чесно про неї написати важливіше, ніж підбирати ракурс, у якому «щось наче проглядається».

Графік 1. Як розподілені значення вашого потоку?


Побудуйте гістограму вашого потоку (середнє за годину). Порахуйте окремо середнє й медіану цього стовпця.

Якщо гістограма вийде нечитабельною — стовпчик біля нуля і порожньо далі — не залишайте так. Спробуйте побудувати гістограму від логарифма значень (`np.log10`) і подивіться, що зміниться.

Питання: чому середнє й медіана так сильно відрізняються?

```
In [70]: # ВАШ КОД
hist_data = M.loc[M[('P >50', 'mean')]>0, [('P >50', 'mean')]].dropna()
plt.figure(figsize=(10, 6))
plt.hist(
    np.log10(hist_data),
    bins=100,
    color="#3498db",
    edgecolor="white",
    alpha=1,
    density=True,
)
plt.title(
    "Гістограма для P > 50 (log10)"
)
```

```
plt.axvline(
    np.log10(M['P >50', 'mean']).mean(),
    color="red",
    linestyle="--",
    linewidth=2,
    label=f"Середнє: {M['P >50', 'mean'].mean():.2f}, log10 {np.log10(M['P >50', 'mean']).mean():.2f}"
)
plt.axvline(
    np.log10(M['P >50', 'mean']).median(),
    color="black",
    linestyle="--",
    linewidth=2,
    label=f"Медіана: {M['P >50', 'mean'].median():.2f}, log10 {np.log10(M['P >50', 'mean']).median():.2f}"
)
plt.xlabel("Потік P > 50 (log10)")
plt.ylabel("Щільність (Frequency Density)")
plt.legend()
plt.grid(True)
plt.show()
```



Висновок: Значення потоку P > 50 значною мірою схилиються близько до $10^{-1.2}$, проте присутній довгий хвіст з великих значень, що спотворює гістограму при невикористанні логарифму та спричинює таку розбіжність між середнім (7.43) та медіаною (0.08).

Графік 2. Чи відрізняється швидкість вітру між групами годин?


Побудуйте діаграму розмаху (`boxplot`) швидкості сонячного вітру окремо для кожної групи з завдання 4.4.

```
In [49]: # ВАШ КОД
groups = ['тиха', 'активна', 'дуже активна']

data = [M.loc[M['група'] == g, 'SPEED'].dropna() for g in groups]

plt.figure(figsize=(8, 5))
bp = plt.boxplot(data, tick_labels=groups, showmeans=True, patch_artist=True)
for box in bp['boxes']:
    box.set_facecolor('#aed6f1')
plt.title('Швидкість сонячного вітру за групами годин')
plt.xlabel('Група годин за максимумом потоку P>10')
plt.ylabel('Швидкість сонячного вітру, км/с')
plt.grid(True, axis='y')
plt.show()

M.groupby('група')['SPEED'].describe()
```



Out[49]:

	count	mean	std	min	25%	50%	75%	max
група								
активна	171.0	515.05848	103.401087	350.0	447.5	492.0	557.0	806.0
дуже активна	18.0	552.944444	21.631873	469.0	555.0	556.0	557.0	575.0
тиха	412.0	501.007282	134.982607	0.0	440.25	517.5	599.0	795.0

Висновок: Швидкість вітру не залежить від активності потоку (медіани ~500, медіану 556 та малий розкид для "дуже активної" групи можна пояснити малою вибіркою, прямокутник та вуса лежать приблизно однаково для обох інших груп, у активної він навіть трохи менший)

Графік 3. Чи пов'язані змінні вашої пари?

Побудуйте діаграму розсіювання для пари з вашого завдання. Порахуйте коефіцієнт кореляції між ними.

```
In [50]: # ВАШ КОД
corr = M[['SPEED', ('P >10', 'max')]].corr().to_numpy()
print(f'Correlation: {corr[0,1]}')

plt.figure(figsize=(7,5))
plt.scatter(
    M["SPEED"], M[('P >10', 'max')], color="royalblue", alpha=0.7, edgecolor
)


plt.xlabel("SPEED", fontsize=11)
plt.ylabel("P > 10", fontsize=11)
plt.grid(True, linestyle="--", alpha=0.6)
plt.legend()

plt.show()
```

Correlation: 0.08856160778553436

/tmp/ipykernel_2286/1323394169.py:13: UserWarning: No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when legend() is called with no argument.

```
plt.legend()
```



Висновок: Лінійна кореляція між швидкістю та потоком $P > 10$ відсутня (коєф 0.089), можлива нелінійна кореляція з високими $P > 10$ в районі швидкості 400-500, але це легше пояснити часовим співпадінням

Графік 4. Скільки годин у кожній групі?


Побудуйте стовпчикову діаграму кількості годин за групами. Підпишіть кожен стовпчик кількістю годин і відсотком від загальної кількості.

```
In [51]: # ВАШ КОД
groups = ['тиха', 'активна', 'дуже активна']
counts = M['група'].value_counts().reindex(groups, fill_value=0)
percentage = counts / counts.sum() * 100

plt.figure(figsize=(7, 5))
bars = plt.bar(counts.index, counts.values, color=['#85c1e9', '#f5b041', '#e69d00'])

for bar, n, p in zip(bars, counts.values, percentage.values):
    plt.text(bar.get_x() + bar.get_width() / 2, bar.get_height(),
             f'{n} год\n({p:.1f}%)', ha='center', va='bottom', fontsize=9)

plt.title('Кількість годин у кожній групі')
plt.xlabel('Група')
plt.ylabel('Кількість годин')
plt.grid(True, axis='y')
plt.show()
```



Висновок: 68.6% годин є тихими, 28.5 активними та 3 дуже активними

Графік 5. Як усе це виглядало в часі?

Побудуйте лінійний графік максимуму потоку $P > 10$ за годину за весь період спостережень.

Якщо крива виявиться нечитабельною — згадайте, що допомогло в графіку 1.

```
In [52]: # ВАШ КОД
series = M[('P >10', 'max')]

plt.figure(figsize=(12, 4))
plt.plot(M['ts'], series, color='#2a78d6', linewidth=1)
plt.yscale('log')
plt.title('Максимум потоку P>10 за годину')
plt.xlabel('Час')
plt.ylabel('Максимум потоку P>10')
plt.grid(True, which='both', alpha=0.3)
plt.show()
```



```
In [53]: # ВАШ КОД
series = M[('P >10', 'max')].where(M['ts'] > pd.Timestamp("2017-09-09 00:00:"))

plt.figure(figsize=(12, 4))
plt.plot(M['ts'], series, color='#2a78d6', linewidth=1)
plt.yscale('log')
plt.title('Максимум потоку P>10 за годину (з 9 вересня)')
plt.xlabel('Час')
plt.ylabel('Максимум потоку P>10')
plt.grid(True, which='both', alpha=0.3)
plt.show()
```



Висновок: наявний спалах потоку P>10 з 5 по 9 та з 10 по 15 вересня. Також можна побачити, де саме значення перевищило 1000, а також малий розброс у часі, що пояснює аномалії на інших графіках, особливо там, де було групування по цьому значенню

Етап 6. Два графіки одних і тих самих даних

Нижче побудовано два графіки. Дані в них **одні й ті самі** — це той самий стовпець з тієї самої таблиці, жодне число не змінено.

Виконайте клітинку й подивіться на обидва.

```
In [54]: СТОВПЕЦЬ = ('P >10', 'max') # <- впишіть назву свого стовпця з МАКСИМУМОМ


вікно = M[(M['ts'] >= '2017-08-28') & (M['ts'] < '2017-09-05')]

fig, ax = plt.subplots(1, 2, figsize=(12, 3.2))

ax[0].plot(вікно['ts'], вікно[СТОВПЕЦЬ], color='#2a78d6')
ax[0].set_title('Графік 1')
ax[0].tick_params(axis='x', rotation=30)

ax[1].plot(M['ts'], M[СТОВПЕЦЬ], color='#2a78d6')
ax[1].set_yscale('log')
ax[1].set_title('Графік 2')
ax[1].tick_params(axis='x', rotation=30)

fig.tight_layout()
plt.show()
```



Завдання 6.1

Дайте відповідь на три питання:

1. Який висновок про космічну погоду у вересні 2017 року зробить людина, яка бачила **тільки перший** графік?
2. Який висновок зробить людина, яка бачила **тільки другий**?
3. Чим ці два графіки відрізняються між собою? Назвіть **дві** відмінності — вони обидві є в коді вище.

Жодне число в обох графіках не підроблене. Різниця виникла тільки через те, як їх побудували.

Відповідь 6.1:

1. Висновок з першого графіка: 5 вересня стався великий спалах, що далі - невідомо

2. Висновок з другого графіка: від 5 до 9 та від 10 до 15 вересня були два середньо-високі спалахи активності
3. Дві відмінності між ними: перший графік не в log scale та обрізаний, другий - навпаки

Завдання 6.2

Уявіть, що вам потрібно **одним графіком** чесно показати, що відбувалося в цьому періоді. Побудуйте його самі й підпишіть заголовком, який формулює висновок.

Поясніть у клітинці нижче, чому ви обрали саме такий вигляд.

```
In [55]: # ВАШ КОД
series = M[('P >10', 'max')]

plt.figure(figsize=(12, 4))
plt.plot(M['ts'], series, color='#2a78d6', linewidth=1)
plt.yscale('log')
plt.axhline(10, color='gray', linestyle='--', linewidth=1)
plt.axhline(1000, color='gray', linestyle='--', linewidth=1)
plt.title('Сонячна активність')
plt.xlabel('Час')
plt.ylabel('Максимум потоку P>10 за годину')
plt.grid(True, which='both', alpha=0.3)
plt.show()
```



Відповідь 6.2: Я використав log scale, бо в іншому випадку всі дані злились би до нуля, окрім великих спалахів. Також я додав горизонтальні лінії на 10 та 1000, щоб відобразити пороги NOAA, які визначали групи

Етап 7. Три спостереження та ваше питання

Завдання 7.1

Запишіть **три спостереження** про ці дані, які ви зробили під час роботи.

Спостереження — це твердження, яке спирається на конкретне число або графік з вашого ноутбука. Не «дані цікаві», а, наприклад, «максимальне значення потоку у 2000 разів більше за медіанне, і всі такі години припадають на одні й ті самі три доби».

Для кожного вкажіть, **де саме** у вашій роботі його видно.

Спостереження 1: значення потоку набагато зручніше відобразити в log scale, бо фонові активності набагато нижчі за спалахи та повністю ними перебиваються, а самі спалахи теж зростають експоненційно, що унеможливорює порівняння в лінійному масштабі двох різних спалахів

Спостереження 2: максимальне значення ледве перетнуло позначку 1000 та тривало дуже мало (менше одного дня), що спричинило малу вибірку для групи 'дуже активно'

Спостереження 3: відсутня лінійна кореляція між швидкістю сонячного вітру та значенням потоку, аномалію на скатерплоті можна пояснити часовим збігом

Завдання 7.2 — ваше індивідуальне питання

Дайте відповідь на додаткове питання зі свого завдання. Відповідь має спиратися на обчислення: наведіть код і результат, а потім сформулюйте висновок словами.

```
In [56]: # ВАШ КОД
M = M.sort_values('ts').reset_index(drop=True)

active = M['група'].isin(['активна', 'дуже активна'])
runs = (active != active.shift()).cumsum()

lengths = active.groupby(runs).sum()
starts = M.loc[active, 'ts'].groupby(runs).min()
ends = M.loc[active, 'ts'].groupby(runs).max()

active_runs = pd.DataFrame({'годин': lengths, 'від': starts, 'до': ends})
active_runs = active_runs[active_runs['годин'] > 0].sort_values('годин', ascending=True)

print('Найдовша неперервна серія активних годин:', active_runs['годин'].iloc[0])
print('Від:', active_runs['від'].iloc[0], 'до:', active_runs['до'].iloc[0])
print()
print(active_runs)
```

Найдовша неперервна серія активних годин: 98
Від: 2017-09-10 16:00:00 до: 2017-09-14 17:00:00

	годин	від	до
група			
6	98	2017-09-10 16:00:00	2017-09-14 17:00:00
2	87	2017-09-05 00:00:00	2017-09-08 14:00:00
4	4	2017-09-08 17:00:00	2017-09-08 20:00:00

Відповідь 7.2: Якщо рахувати "активна" як "дуже активна" також, то найдовша серія тривала 98 годин, а саме з 10 вересня 16:00 по 14 вересня 17:00

Етап 8. Декларація про використання інструментів штучного інтелекту

Користуватися мовними моделями під час виконання цієї роботи **дозволено**. Це нормальна інженерна практика, і курс про штучний інтелект не має підстав її забороняти.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення.

Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок вашого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Якщо код згенеровано, але ви його розумієте — робота зарахована. Якщо не розумієте — не зарахована, незалежно від того, хто його написав.

Завдання 8.1

Заповніть словник. Для кожного етапу оберіть одне з формулювань:

- 'ні' — інструментами ШІ не користувався;
- 'синтаксис' — питав про назву функції або синтаксис, код писав сам;
- 'код, перевірено' — код згенеровано, я його прочитав, перевірів і розумію;
- 'текст, перероблено' — згенеровано чернетку тексту, яку я переписав по суті;
- 'текст, як є' — згенерований текст залишено майже без змін.

Останній варіант не заборонений, але прямо впливає на оцінку: бали ставляться за висновки, а не за наявність абзацу.

```
In [57]: ІНСТРУМЕНТИ_ШІ = 'Gemini, Kilo code (deepseek v4.1 flash)'      # напр. 'Chat

ДЕКЛАРАЦІЯ = {
    'етапи 1–2, читання файлу та розбір таблиць': 'синтаксис',
    'етап 3, паспорт даних і дивні значення':      'синтаксис',
    'етап 4, об'єднання таблиць':                  'синтаксис',
    'етап 5, побудова графіків':                    'код, перевірено',
    'етап 5, формулювання висновків':               'ні',
    'етапи 6–7, порівняння графіків і спостереження': 'код, перевірено',
}

# Що саме ви перевірили за згенерованим кодом чи текстом – конкретно:
# які числа звірили, що переписали, де знайшли помилку.
ЩО_ПЕРЕВІРЕНО = 'відповідність коду опису проблеми, відсутність \
непотрібних речей (імпортів, декорацій, тексту, інших ознак ШІ-слопу) \
у коді, зрозумілість коду'

# True означає: я можу пояснити кожен рядок свого коду, відтворити будь-який
# результат цієї роботи та внести зміни в код на вимогу під час захисту.
ПІДТВЕРДЖУЮ = True
```

```
In [58]: # --- перевірка повноти декларації: клітинку не редагувати -----
ДОЗВОЛЕНІ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено', 'те

assert ІНСТРУМЕНТИ_ШІ.strip(), 'Вкажіть інструменти або напишіть «не викорис
порожні = [k for k, v in ДЕКЛАРАЦІЯ.items() if not str(v).strip()]
assert not порожні, 'Не заповнено пункти декларації: %s' % ' '.join(порожні)
чужі = {v for v in ДЕКЛАРАЦІЯ.values() if v not in ДОЗВОЛЕНІ}
assert not чужі, 'Недопустимі значення: %s. Оберіть з переліку вище.' % ' ', '
assert len(ЩО_ПЕРЕВІРЕНО.strip()) >= 120, ('Опишіть конкретніше, що саме ви
                                     '(зараз %d символів, потрібно щон
                                     % len(ЩО_ПЕРЕВІРЕНО.strip()))

assert ПІДТВЕРДЖУЮ is True, 'Підтвердьте, що можете пояснити власний код на

print('ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ')
print('=' * 78)
print('%-46s %s' % ('автор:', ПІБ))
print('%-46s %s' % ('інструменти:', ІНСТРУМЕНТИ_ШІ))
print('-' * 78)
for k, v in ДЕКЛАРАЦІЯ.items():
    print('%-46s %s' % (k + ':', v))
print('-' * 78)
print('перевірено автором:')
print(ЩО_ПЕРЕВІРЕНО)
print('=' * 78)
print('Автор підтверджує, що може пояснити кожен рядок коду під час захисту.
```

ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ

```
=====
==
автор: Білоусов Михайло
інструменти: Gemini, Kilo code (deepseek v
4.1 flash)
-----
--
етапи 1–2, читання файлу та розбір таблиць: синтаксис
етап 3, паспорт даних і дивні значення: синтаксис
етап 4, об'єднання таблиць: синтаксис
етап 5, побудова графіків: код, перевірено
етап 5, формулювання висновків: ні
етапи 6–7, порівняння графіків і спостереження: код, перевірено
-----
--
перевірено автором:
відповідність коду опису проблеми, відсутність непотрібних речей (імпортів,
декорацій, тексту, інших ознак ШІ-слопу) у коді, зрозумілість коду
=====
==
Автор підтверджує, що може пояснити кожен рядок коду під час захисту.
```

Крок 9. Збереження результату та фінальна самоперевірка

Об'єднана таблиця знадобиться вам у лабораторних роботах № 3 і № 4 — збережіть її й не втрачайте до кінця семестру.

```
In [59]: M.to_csv('master_hourly.csv', index=False)
print('збережено:', M.shape)
```

збережено: (601, 21)

```
In [60]: # --- фінальна самоперевірка -----
перевірки = {
    'ПІБ і варіант заповнено': bool(ПІБ) and bool(ВАРІАНТ),
    'таблиця A (7200 рядків)': len(A) == 7200,
    'таблиця B (25 рядків)': len(B) == 25,
    'таблиця C (601 рядок)': len(C) == 601,
    'таблиці об'єднано': M is not None and 590 <= len(M) <= 605,
    'стовпець «група» є': 'група' in M.columns,
    'усі дати у 2017 році': int(pd.to_datetime(M['ts']).dt.year.min()) == 2017,
    'декларацію заповнено': bool(ІНСТРУМЕНТИ_ШІ.strip()) and ПІДТЕ
}
for k, v in перевірки.items():
    print(('OK' if v else 'НЕ OK') + ' ' + k)

if all(перевірки.values()):
    print('\nТехнічна частина роботи виконана.')
```

```
print('Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та в  
print('і виконайте Kernel → Restart & Run All перед задачею.')
```

OK ПІБ і варіант заповнено
OK таблиця А (7200 рядків)
OK таблиця В (25 рядків)
OK таблиця С (601 рядок)
OK таблиці об'єднано
OK стовпець «група» є
OK усі дати у 2017 році
OK декларацію заповнено

Технічна частина роботи виконана.

Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та висновками,
і виконайте Kernel → Restart & Run All перед задачею.